



INSIEME DI APPROCCI PER LA SEGMENTAZIONE 3D DEL TUMORE CEREBRALE

Laureando:

Christian Francesco Russo

Relatore:

Prof. Loris Nanni



Problema e soluzioni esistenti



- I **tumori cerebrali** sono forme tumorali che colpiscono il sistema nervoso centrale, ossia l'insieme di encefalo, midollo allungato e cervelletto.
- La soluzione migliore per <u>diagnosticare</u> i tumori cerebrali è la risonanza magnetica (MRI),
 o in alternativa la tomografia computerizzata (TC).
- In questi ultimi anni sono stati sviluppati diversi approcci di deep learning per eseguire la segmentazione semantica di immagini mediche. Questi approcci sono largamente utilizzati in ambito di diagnosi medica, in quanto presentano i seguenti vantaggi:
 - Permettono di ottenere risultati migliori di quelli di un operatore umano esperto
 - Permettono di far risparmiare molto tempo



Volume di partenza



Volume segmentato



Soluzioni proposte



- Per questo lavoro di tesi sono stati proposti 3 diversi approcci per eseguire la segmentazione semantica binaria 3D di volumi MRI cerebrali:
 - o **1° approccio 'weak':** segmentazione a livello di slice 2D di volume. Questo metodo è basato su DeepLabV3+ e sfrutta una rete ResNet come backbone.
 - 2° approccio 'weak': segmentazione a livello di patch 3D di volume. Questo metodo è basato su U-Net 3D.
 - 3° approccio 'strong': ensemble dei primi due approcci 'weak'
- **Lo scopo** è quello di provare a migliorare quello che ad oggi è lo stato dell'arte delle attuali tecniche di riconoscimento del tumore cerebrale.
- Ogni rete 'weak' viene addestrata utilizzando una **loss function** scelta tra una pletora di loss function differenti.



Primo approccio 'weak'

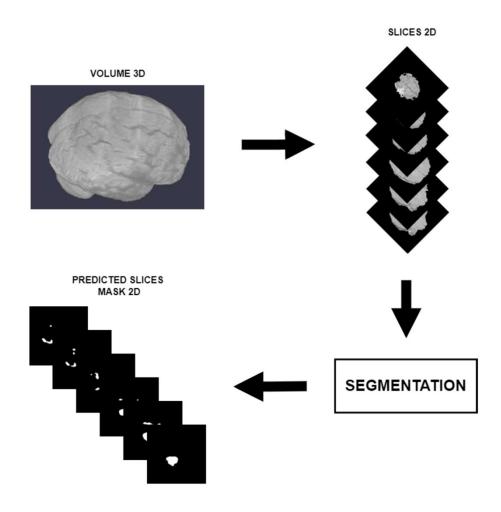


Elaborazione dei dati:

- Pre-processing dei dati
- Slicing dei dati
- Filtraggio delle slice
- Creazione training set, validation set e test set

Segmentazione 2D:

- Architettura: DeepLabV3+
- Rete backbone: ResNet-101 (finetuning)

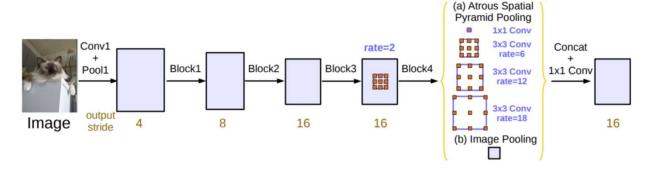




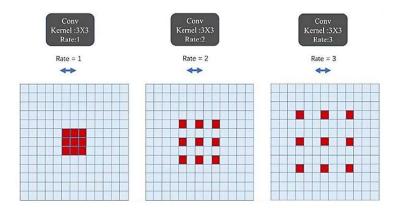
DeepLabV3



Architettura DeepLabV3

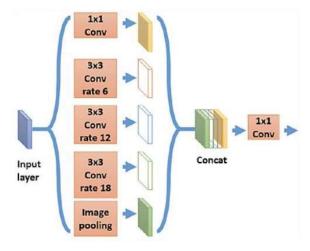


Atrous Convolution



Con un solo layer permette di leggere feature map in input a qualsiasi risoluzione di campionamento. Permette di estrarre feature map a risoluzione maggiore (più dense), con un basso costo computazionale.

Atrous Spatial Pyramid Pooling (ASPP)



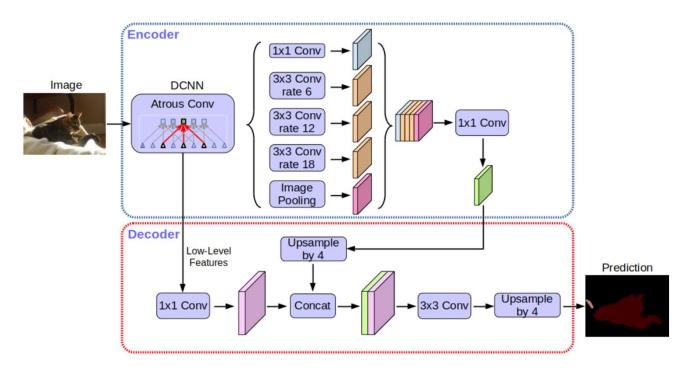
Rimuove vincolo dimensione fissa dell'immagine in input. Rappresentazione multi-scala dell'immagine in input. Contiene la previsione della classe di ogni pixel.



DeepLabV3+



Architettura DeepLabV3+



- Problema: con DeepLabV3 i bordi degli oggetti nelle immagini risultano sfocati
- Nota: non è possibile usare l'Atrous convolution per estrarre feature map più dense a causa dei limiti di memoria delle GPU
- **Soluzione:** unione metodi e vantaggi di DeepLabV3 e dell'architettura encoder-decoder
- **Decoder:** risolve il problema di DeepLabV3 dei bordi degli oggetti sfocati nelle immagini



Secondo approccio 'weak'

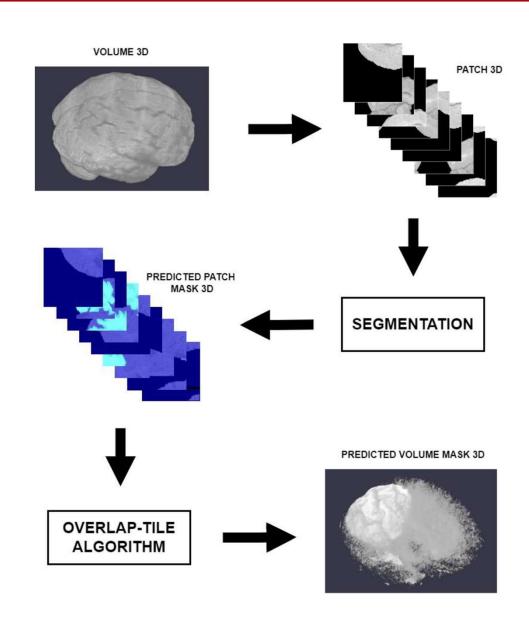


Elaborazione dei dati:

- Pre-processing dei dati
- Creazione training set, validation set e test set
- Patching dei dati
- Data augmentation

Segmentazione 3D:

Architettura: U-Net 3D

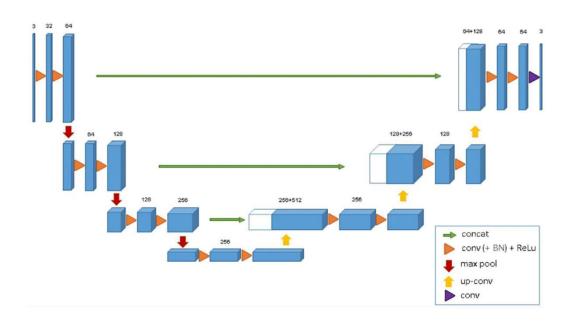




U-Net 3D



Architettura U-Net 3D



3 sezioni:

- **Sezione contrazione:** ogni blocco contiene:
 - 2 layer convolutivi 3x3x3
 - 1 layer max-pooling 2x2x2 (per downsampling)
- **Sezione espansione:** ogni blocco contiene:
 - 2 layer convolutivi 3x3x3
 - 1 layer up-convolution 2x2x2 (per upsampling)
- **Sezione bottleneck:** contiene:
 - 1 layer max-pooling 2x2x2
 - 2 layer convolutivi 3x3x3
 - 1 layer up-convolution
- **Sezione contrazione:** riduzione risoluzione volume, classificazione dei pixel, costo computazionale basso.
- **Sezione espansione:** recupero informazioni spaziali: il volume viene riportato alla risoluzione originale. Alle feature map di ogni livello di espansione vengono aggiunte in coda le feature map del corrispondente livello di contrazione, in modo che le feature map apprese durante la fase si contrazione vengano utilizzate per ricostruire il volume.
- Ogni layer convolutivo è seguito da un layer di batch normalization e da un layer ReLU.



Terzo approccio: Ensemble

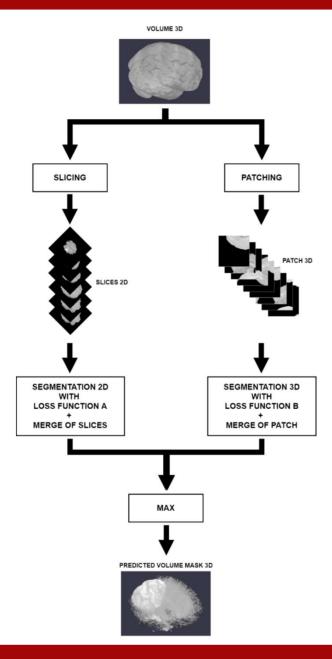


Elaborazione dei dati:

- Pre-processing dei dati
- Creazione test set

Ensemble:

Un ensemble per ogni coppia di reti 'weak', ottenute dai due approcci precedenti, dove ogni rete è addestrata per ogni loss function proposta





Loss Functions



Elenco delle loss functions proposte:

- Dice Loss
- Binary Cross-Entropy
- Weighted Cross-Entropy
- Balanced Cross-Entropy
- Focal Loss
- Twersky Loss
- Focal Twersky Loss
- Focal Dice Loss
- Log-Cosh Dice Loss
- Log-Cosh Twersky Loss
- Exponential Logarithmic Loss
- Dual Cross-Entropy

- Dual Focal Loss
- Noise Robuste Dice Loss
- Sensitivity Specificity Loss
- Combinazioni di Loss:
 - Focal Twersky Loss + Focal Dice Loss
 - Log-Cosh Dice Loss + Focal Dice Loss+ Log-Cosh Focal



Risultati



- Per motivi di tempo non è stato possibile effettuare l'addestramento e i test delle reti su server multi-GPU.
- Il funzionamento del codice è stato testato sul mio computer.
- Tutte le reti addestrate sul mio computer hanno richiesto un settaggio degli iperparametri con valori molto bassi, in modo da non saturare le risorse del computer. Per questo motivo i risultati ottenuti dai test, nonostante siano validi, non sono degni di nota e pertanto ho deciso di non riportarli in questa sezione.

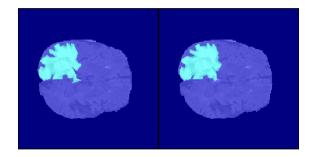


Conclusioni



Conclusioni:

• In attesa che le reti vengano addestrate su server, è possibile iniziare fare una previsione su quali loss function ci si aspetta che daranno risultati migliori.



 Mi aspetto che le loss function che daranno risultati migliori saranno quelle progettate per lavorare su classi fortemente sbilanciate e/o quelle progettate per lavorare su regioni di foreground molto irregolari, per esempio:

Dice Loss, Focal Loss, Focal Twersky Loss e Focal Dice Loss

Sviluppi futuri:

- Training e test delle reti su server per verificare la bontà dei metodi proposti
- Test di nuove loss function e di nuove loss function composte
- Creare nuovi approcci 'weak' per migliorare l'ensemble
- Testare ensemble ottenuto dal secondo approccio proposto (patch casuali)





FINE

Grazie per la vostra attenzione!
Ci sono domande?